

流感病毒风险预测工具使用说明

本工具通过识别基因组或蛋白质序列中与五类表型相关的氨基酸分子标志物，计算这五类表型的风险评分，以提供甲型流感病毒的风险评估和早期预警。这些表型包括：人体适应性、传播性、受体结合能力、毒力和耐药性。此外，该工具还提供自动序列注释，评估病毒与疫苗之间的抗原关系，并预测流感病毒的宿主、致病性及受体结合偏好。

预备工作：软件依赖安装

安装diamond

diamond是一款高性能的序列比对工具，用于快速比对蛋白质序列。安装方法如下：

1. 使用Conda安装（推荐）：

```
conda install -c bioconda diamond
conda install -c bioconda diamond=2.1.11
```

2. 直接下载二进制文件：访问 [Diamond官方网站](#) 下载适合您系统的版本。脚本使用的是 diamond-2.1.11。

一、安装

```
conda create -n FluRisk-env python=3.6
conda activate FluRisk-env
unzip FluRisk.zip
mkdir FluRisk && cd FluRisk
pip install .
```

二、测试/使用

1. 直接运行测试文件

```
python3 test.py
```

2. 手动测试

1) 序列注释

目的： 进行流感病毒序列的注释，通过diamond/BLAST与流感病毒宿主数据库比对，评估病毒与疫苗的抗原关系并预测重配指数。

参数说明：

- **-i** 参数：指定包含一个或多个fasta格式的流感病毒毒株序列文件的目录路径，每个文件代表一个流感病毒毒株，或者指定单个流感病毒毒株序列的fasta文件路径。
- **-u** 参数：指定存放注释和标准化后的fasta格式流感病毒蛋白质序列文件的目录，默认为 standardized_fasta/。

- `temp` 参数：临时文件目录，默认为temp/
- `-o` 参数：指定输出目录路径。

```
cd test
flupre anno -i test_files/ -o result/
```

输出结果说明

- `standardized_fasta/`:
 - 如果输入为核苷酸序列，则存放经过注释和标准化后的每个流感病毒毒株蛋白质序列文件，文件名后缀为.trans2protein.fasta.stdName.annotation.fa。
 - 如果输入为蛋白质序列，则存放经过标准化后的每个流感病毒毒株蛋白质序列文件，文件名后缀为.stdName.annotation.fa。

标准化主要指的是标准化序列id。

 test1.fasta.stdName.annotation.fa	5,104 FA 文件	2025-03-25 22:21
 test2.fa.stdName.annotation.fa	4,624 FA 文件	2025-03-25 22:23
 test3.stdName.annotation.fa	5,104 FA 文件	2025-03-25 22:25
 test4.trans2protein.fasta.stdName.annotation.fa	5,126 FA 文件	2025-03-25 22:27

- `result/`
 - 生成以下四个文件。

 EPI_ISL_66173.stdName.annotation.fas.antigenInfo.blast.csv	476 XLS 工作表	2025-03-25 22:13	-rw-rw-r--
 EPI_ISL_66173.stdName.annotation.fas.antigenInfo.csv	16,688 XLS 工作表	2025-03-25 22:12	-rw-rw-r--
 EPI_ISL_66173.stdName.annotation.fas_reassortment_risk.csv	176 XLS 工作表	2025-03-25 22:12	-rw-rw-r--
 EPI_ISL_66173_annotation_for_anno.csv	673 XLS 工作表	2025-03-25 22:13	-rw-rw-r--

1. **antigenInfo.blast.csv** — 与参考株进行BLAST比对后得到的前5种最相似的HA蛋白质，以及它们之间的抗原和遗传关系。
2. **antigenInfo.csv** — 预测的流感病毒株与疫苗株之间的抗原和遗传关系（适用于H1、H3、H5、H7和H9）。
3. **reassortment_risk.csv** — 与流感病毒宿主数据库比对后计算得到的重配指数及其详细信息。
4. **for_anno.csv** — 流感病毒的序列注释结果文件。

2) 标志物识别

目的：识别与流感病毒五种表型相关的氨基酸分子标志物。

参数说明：

- `-i` 参数：指定存放了标准化后的每个流感病毒毒株序列文件的目录路径，即 `standardized_fasta/`。
- `-a` 参数：指定存放了每个流感病毒注释结果文件的目录路径，即 `result/`。
- `-o` 参数：指定输出路径，存放五种表型对应的标志物结果目录，默认在当前目录生成五个文件夹。
- `-p` 参数：指定输出文件名前缀

```
flupre extract -i standardized_fasta/ -a result
```

输出结果说明

文件夹名与表型的对应关系如下。

```
phenotype_descriptions = {
    'transmissibility': 'Mammalian Transmissibility',
    'binding': 'Human Receptor Binding Ability',
    'adaptation': 'Mammalian Adaptability',
    'virulence': 'Mammalian Virulence',
    'resistance': 'Drug resistance'
}
```

每个文件夹下都是识别到的对应表型的氨基酸分子标志物的CSV文件。一个文件对应一个流感病毒毒株。

输出目录结构：

```
adaptation/      # 哺乳动物适应性
binding/         # 受体结合能力
transmissibility/ # 传播性
virulence/       # 毒力
resistance/      # 耐药性
```

3) 预测流感病毒宿主类别（禽类/人类）

目的：基于哺乳动物适应性相关的氨基酸分子标志物，预测流感病毒的宿主类别。

参数说明：

- `-i/--input` 参数：必填，输入包含标志物数据的CSV文件或目录
- `-m/--model_path` 参数：自定义预训练宿主预测模型路径，默认为内置模型
- `-t/--threshold` 参数：预测概率阈值，默认为0.5
- `-o/--output_directory` 参数：输出目录，默认为 `host_predictions/`
- `-p/--prefix` 参数：输出文件名前缀，默认为空

```
flupre predh -i adaptation/
```

输出结果说明

在`host_predictions/`下得到两个文件。

1. `prediction.csv`（所有输入毒株的宿主预测结果）
注：该文件`Probability`列代表的是所属类别的概率，而非正类的概率。
2. `combined_markers_matrix.csv`（输入预测模型的特征矩阵）

4) 预测流感病毒毒力水平（有毒/无毒）

目的：基于哺乳动物毒力相关的氨基酸分子标志物，预测流感病毒的毒力水平。

参数说明：

- `-i/--input` 参数：必填，输入包含标志物数据的CSV文件或目录

- `-m/--model_path` 参数：自定义预训练宿主预测模型路径，默认为内置模型
- `-t/--threshold` 参数：预测概率阈值，默认为0.5
- `-o/--output_directory` 参数：输出目录，默认为 `virulence_predictions/`
- `-p/--prefix` 参数：输出文件名前缀，默认为空

```
flupre predv -i virulence/
```

输出结果说明

在 `virulence_predictions/` 下得到两个文件。

1. `prediction.csv`（所有输入毒株的毒力水平预测结果）
注：该文件 `Probability` 列代表的是所属类别的概率，而非正类的概率。
2. `combined_markers_matrix.csv`（输入预测模型的特征矩阵）

5) 预测流感病毒受体结合偏好 ($\alpha 2-3/\alpha 2-6$)

目的：基于哺乳动物人类受体结合相关的氨基酸分子标志物，预测流感病毒的受体结合嗜性。

参数说明：

- `-i/--input` 参数：必填，输入包含标志物数据的CSV文件或目录
- `-m/--model_path` 参数：自定义预训练宿主预测模型路径，默认为内置模型
- `-t/--threshold` 参数：预测概率阈值，默认为0.5
- `-o/--output_directory` 参数：输出目录，默认为 `binding_predictions/`
- `-p/--prefix` 参数：输出文件名前缀，默认为空

```
flupre predb -i binding/
```

输出结果说明

在 `binding_predictions/` 下得到两个文件。

1. `prediction.csv`（所有输入毒株的受体结合偏好预测结果）
注：该文件 `Probability` 列代表的是所属类别的概率，而非正类的概率。
2. `combined_markers_matrix.csv`（输入预测模型的特征矩阵）

6) 预测流感病毒五类表型的风险值

目的：基于五类表型相关的氨基酸分子标志物，预测对应表型的风险值

参数说明：

- `-i` 参数：指定存放了五种表型对应的标志物结果目录的路径。
- `-a` 参数：指定存放了每个流感病毒序列注释结果文件的目录，默认为 `result/`。
- `-hp` 参数：指定存放了每个流感病毒宿主预测结果文件的目录，默认为 `host_predictions/`。
- `-vp` 参数：指定存放了每个流感病毒毒力水平预测结果文件的目录，默认为 `virulence_predictions/`。

- `-bp` 参数：指定存放了每个流感病毒受体结合偏好预测结果文件的目录，默认为 `binding_predictions/`。
- `-o` 参数：指定存放每个流感病毒风险预测结果文件及所有流感病毒风险预测结果文件的目录路径。

```
risk2tab -i ./ -a result/ -o radar_file/  
risk2tab -i ./ -a result/ -hp host_predictions/ -vp virulence_predictions/ -bp  
binding_predictions/ -o radar_file/
```

输出结果说明

radar_file/下得到两类文件。

1. `_risk_values.csv` ——包含每个流感病毒毒株四种表型和六种药物的风险预测值。
2. `summary_risk_values.csv` ——包含所有流感病毒毒株四种表型和六种药物的风险预测值汇总，如下所示。



输出文件：

```
radar_file/  
├─ [strain]_risk_values.csv      # 单个毒株风险值  
└─ summary_risk_values.csv      # 汇总风险值表
```

风险值表结构：

Strain	Mammalian Transmissibility	Human Receptor Binding Ability	Mammalian Adaptability	Mammalian Virulence	zanamivir	...
sample1	0.78	0.62	0.91	0.45	0.12	...
.....						